

Aprendizaje Árboles de decisión

Departamento de Lenguajes y Ciencias de la Computación
Universidad de Málaga




Contenido

- 1. Introducción
- 2. Fundamentos
- 3. Algoritmo ID3
- 4. Inconvenientes y soluciones
- 5. Conclusión



1.INTRODUCCIÓN



1. Introducción

Aprendizaje

- Aprendizaje de observaciones
 - ¿Cómo actuar en el futuro?

- Elementos de aprendizaje
 - Componentes
 - Realimentación
 - Tipo de representación

1. Introducción

Aprendizaje

□ Formas de Aprendizaje

- Componentes: condiciones, método de inferencia, información de cambios, información de utilidad, información acción-valor, metas,...
- Realimentación: supervisado, no supervisado y por refuerzo
- Representación: disponibilidad de conocimiento a priori

1. Introducción

Aprendizaje

Aprendizaje supervisado

- Aprendizaje inductivo:
 - un ejemplo es un par $(x, f(x))$
 - Dado un conjunto de ejemplos de f , encontrar h
 - h (hipótesis), estará bien generalizada si puede predecir o clasificar ejemplos no conocidos
- ¿Cómo elegir entre múltiples hipótesis?
 - Dos enfoques

1. Introducción

Aprendizaje


- Mejor
 - Elegir aquella hipótesis consistente con los datos que sea más sencilla, en otro caso será difícil extraer un *patrón* de los mismos
- Utilizar un espacio de hipótesis tan grande como sea posible
 - No tiene en cuenta la complejidad computacional del aprendizaje

Existe un compromiso entre la expresividad del espacio de hipótesis y la complejidad de encontrar hipótesis sencillas y consistentes dentro de este espacio

1. Introducción

Motivación

- La clasificación de secuencias (ADN, ARN u otras) según determinada función o propiedad es una tarea fundamental de la biología computacional
- Se necesitan métodos de caja blanca, es decir, fácilmente comprensibles



1. Introducción

Visión general

- Este tema sobre árboles de decisión, puede ser **fácilmente entendido** por usuarios que no son informáticos, es fácil de entender e interpretar
- Los árboles de decisión se emplean para **analizar situaciones complejas** y escoger la mejor
- Se estudia un algoritmo clásico para el **aprendizaje de árboles de decisión**, que ha sido mejorado de muchas formas
- Se discuten algunas **dificultades** típicas asociadas con el aprendizaje de árboles, junto con sus posibles **soluciones**



2. FUNDAMENTOS

2. Fundamentos

Conceptos

Inducción con árboles de decisión

- Un **árbol de decisión** representa una función que toma un vector de valores de atributo $\mathbf{x}$ y devuelve una **decisión** y (el valor de salida, también es llamado Atributo Objetivo)
- El árbol debe aprender de un conjunto de **ejemplos** $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ de tamaño N ; es esta una tarea de aprendizaje supervisado
- Tanto las entradas como las salidas pueden ser discretas o continuas
- Aquí solo estudiamos el caso **discreto**, lo que significa que estamos resolviendo un problema de **clasificación**

2. Fundamentos

Estructura

- Un árbol de decisión produce su decisión mediante la realización de una **secuencia de pruebas**
- Cada **nodo interno** prueba el valor de uno de los atributos de entrada A_i
 - Las **ramas** del nodo están etiquetadas con los posibles valores del atributo $v \in \text{Valores}(A_i)$
 - Cada **nodo hoja** especifica un valor y será devuelto por la función
 - Cada **camino** que conduce a un nodo hoja, se puede representar como una sentencia (regla) de lógica proposicional


2. Fundamentos

Muestra (dataset)

Example	Sky	Temperature	Humidity	Wind	PlayTennis
x ₁	Sunny	High	High	Weak	-
x ₂	Sunny	High	High	Strong	-
x ₃	Cloudy	High	High	Weak	+
x ₄	Rainy	Warm	High	Weak	+
x ₅	Rainy	Low	Normal	Weak	+
x ₆	Rainy	Low	Normal	Strong	-
x ₇	Cloudy	Low	Normal	Strong	+
x ₈	Sunny	Warm	High	Weak	-
x ₉	Sunny	Low	Normal	Weak	+
x ₁₀	Rainy	Warm	Normal	Weak	+
x ₁₁	Sunny	Warm	Normal	Strong	+
x ₁₂	Cloudy	Warm	High	Strong	+
x ₁₃	Cloudy	High	Normal	Weak	+
x ₁₄	Rainy	Warm	High	Strong	-

2. Fundamentos

Árbol de decisión de la muestra





3. ALGORITMO ID3

3. Algoritmo ID3

Descripción del Algoritmo (I)

- El algoritmo ID3 toma tres argumentos de entrada: *Ejemplos*, *Atributo Objetivo* y *Atributos*, y devuelve un árbol de decisión
- Si todos los ejemplos tienen el mismo valor objetivo, entonces devuelve un solo nodo etiquetado con ese valor
- Si *Atributos* está vacío, entonces devuelve un único nodo etiquetado con el valor objetivo más frecuente en *Ejemplos*

3. Algoritmo ID3

Descripción del Algoritmo (II)

- De lo contrario, encuentra el atributo A que mejor clasifica *Ejemplos*
- Después de eso, para cada $v \in \text{Valores}(A)$:
 - Añade una nueva rama debajo de la raíz con etiqueta v
 - Sea $\text{Ejemplos}(v)$ el subconjunto de *Ejemplos* con $A=v$
 - Si $\text{Ejemplos}(v)$ está vacío, entonces añade debajo de la rama un nodo hoja etiquetado con el valor objetivo más frecuente en *Ejemplos*
 - De lo contrario, añade debajo de la rama el nuevo subárbol ID3
($\text{Ejemplos}(v)$, Atributo Objetivo, Atributos- $\{A\}$)

3. Algoritmo ID3

Entropía

- Entropía $H(Ejemplos)$ es una medida de incertidumbre para el conjunto de ejemplos
 - Da el número de bits necesarios para codificar los valores objetivo de los ejemplos
 - Son preferibles entropías bajas
 - $H(Ejemplos)=0$, si todos los ejemplos pertenecen a la misma clase, tenemos clasificación perfecta

$$H(Ejemplos) = - \sum_{v \in AtributoObjetivo} \frac{|Ejemplos(v)|}{|Ejemplos|} \log_2 \frac{|Ejemplos(v)|}{|Ejemplos|}$$

3. Algoritmo ID3

Ganancia de Información

- La Ganancia de Información $IG(Ejemplos, A)$ es la diferencia en la entropía cuando *Ejemplos se divide en un atributo A*, es decir, cuánta incertidumbre se reduce en el conjunto de ejemplos después de dividirlo en A
 - Se elige el atributo con la mayor ganancia de información
 - Sea T , el conjunto de todos los subconjuntos obtenidos al dividir *Ejemplos* en A

$$IG(Ejemplos, A) = H(Ejemplos) - \sum_{t \in T} \frac{|t|}{|Ejemplos|} H(t)$$


3. Algoritmo ID3

ID3 para la muestra (dataset) (I)

- Entropia inicial: $H(\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}) = 0.94$
- Elegir un atributo para el nodo raiz:
 - $IG(\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}, \text{Humidity}) = 0.151$
 - $IG(\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}, \text{Wind}) = 0.048$
 - $IG(\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}, \text{Sky}) = \mathbf{0.246}$ (mejor atributo)
 - $IG(\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}, \text{Temperature}) = 0.02$
- Consecuentemente, dividimos $\{\mathbf{x}_1, \dots, \mathbf{x}_{14}\}$ para el atributo *Sky*

3. Algoritmo ID3

ID3 para la muestra (dataset) (II)




3. Algoritmo ID3

ID3 para la muestra (dataset) (III)

- Para el nodo $Sky=Sunny$ tenemos una entropía inicial $H(S_{Sunny})=0.971$, con $S_{Sunny}=\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_8, \mathbf{x}_9, \mathbf{x}_{11}\}$
- Elegir un atributo para el nodo $Sky=Sunny$:
 - $IG(S_{Sunny}, Humidity)=\mathbf{0.971}$ (mejor atributo)
 - $IG(S_{Sunny}, Wind)=0.019$
 - $IG(S_{Sunny}, Temperature)=0.570$
- Consecuentemente, dividimos S_{Sunny} para el atributo $Humidity$

3. Algoritmo ID3


ID3 para la muestra (dataset) (IV)



3. Algoritmo ID3

ID3 para la muestra (dataset) (V)

- Para el nodo $Sky=Rainy$ tenemos una entropia inicial $H(S_{Rainy})=0.971$, con $S_{Rainy}=\{\mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_{10}, \mathbf{x}_{14}\}$
- Elegimos un atributo para el nodo $Sky=Rainy$:
 - $IG(S_{Rainy}, Humidity)=0.820$
 - $IG(S_{Rainy}, Wind)=\mathbf{0.971}$ (mejor atributo)
 - $IG(S_{Rainy}, Temperature)=0.820$
- Consecuentemente, dividimos S_{Rainy} para el atributo $Wind$
- El árbol de decisión final es el que se muestra en la sección anterior



4. INCONVENIENTES y SOLUCIONES

4. Inconvenientes y soluciones

Inconvenientes del algoritmo ID3

- ID3 presenta algunos **inconvenientes**:
 - Realiza una **búsqueda en escalada** de todos los árboles de decisión. Sin retroceso (peligro de óptimos locales)
 - **Sesgo inductivo**: se prefieren árboles más cortos sobre los más largos
 - Principio de la navaja de Occam - En igualdad de condiciones la solución más sencilla es probablemente la correcta
 - **Sobreajuste**: es posible que el árbol de decisiones producido dé buenos resultados para los datos de entrenamiento, pero deficiente para otros datos

4. Inconvenientes y soluciones


Causas

- Algunas posibles causas de sobreajuste son:
 - El conjunto de entrenamiento es demasiado pequeño, por lo que representa una **versión simplificada** del problema real
 - El algoritmo produce un árbol demasiado especializado en detalles **irrelevantes** del conjunto de entrenamiento
 - Hay **ruido** en el conjunto de entrenamiento, es decir, ejemplos con valores objetivo incorrectos

4. Inconvenientes y soluciones

Soluciones

- **Retroceso (Backtracking)** se puede utilizar para reemplazar la escalada
 - De esta manera se pueden encontrar árboles con mejor rendimiento (y posiblemente más largos)
- Posibles soluciones para el sobreajuste incluyen:
 - **Parada anticipada:** detener el aprendizaje antes de que el árbol se ajuste perfectamente a todos los datos de entrenamiento
 - **Podar:** después de aprender, se usa un conjunto de validación separado para cortar las partes irrelevantes del árbol. Los nodos podados se sustituyen por nodos hoja etiquetados con el valor objetivo más frecuente



5. CONCLUSIÓN

5. Conclusión

Resumen

- ❑ Los **árboles de decisión** se pueden utilizar para resolver problemas de **clasificación**
- ❑ Hay una **representación natural** del conocimiento, la cual puede ser fácilmente entendida por humanos
- ❑ El **algoritmo de aprendizaje ID3** produce un árbol a partir de un conjunto de datos de entrenamiento
- ❑ Puede aparecer **sobreajuste**, pero se puede evitar mediante una parada temprana o una poda

5. Conclusión

Repercusión

- El algoritmo C4.5, es una mejora del algoritmo ID3, y se erige como uno de los mejores clasificadores conocidos hasta la fecha
 - Se caracteriza por una buena combinación de precisión y velocidad
- Los árboles de decisión se utilizan habitualmente para la clasificación de secuencias biológicas, el diagnóstico médico y muchas otras aplicaciones bioinformáticas