


Aprendizaje Regresión Lineal

Departamento de Lenguajes y Ciencias de la Computación
Universidad de Málaga



Contenidos

- 1. Introducción
- 2. Definición del problema
- 3. Función de pérdida y función de coste
- 4. Descenso del gradiente
- 5. Conclusión



1. INTRODUCCIÓN

1. Introducción

Aprendizaje supervisado


- Cuando la salida pertenece a un conjunto finito de valores, decimos que es una tarea de **CLASIFICACIÓN**.
- Cuando la salida pertenece a un intervalo de números reales decimos que es una tarea de **REGRESIÓN**.

1. Introducción

Algunos conceptos fundamentales

La regresión lineal es una técnica muy importante (seguramente ya la conoces). Además, nos servirá para presentar algunos conceptos fundamentales para el aprendizaje automático:


- ❑ **Función de pérdida y regularización**
- ❑ **Método del descenso del gradiente (GD)**
- ❑ **Método del descenso estocástico del gradiente (SGD)**



2. DEFINICIÓN DEL PROBLEMA

2. Definición del problema

Ejemplo



(a)

Figure 19.13 (a) Data points of price versus floor space of houses for sale in Berkeley, CA, in July 2009, along with the linear function hypothesis that minimizes squared-error loss: $y = 0.232x + 246$.

2. Definición del problema

Conjunto de datos

- Conjunto de datos: una sucesión finita

$$\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}.$$

- Cada $\mathbf{x}_j$ es un vector $(x_{j,1}, \dots, x_{j,n})$ de n componentes que son números reales (entrada).
- Cada y_j es un número real (salida).
- En el ejemplo anterior:

$$N = 47, \quad n = 1$$

- y, por ejemplo,

$$\mathbf{x}_3 = (x_{3,1}) = (690), \quad y_3 = 385$$

2. Definición del problema

Espacio de hipótesis

- Espacio de hipótesis $\mathcal{H}$ (de donde se elige la solución): el conjunto de todas las funciones lineales $h_{\mathbf{w}}$ de n variables:

$$h_{\mathbf{w}}(\mathbf{x}_j) = w_0 + w_1 x_{j,1} + \cdots + w_n x_{j,n} = w_0 + \sum_i w_i x_{j,i}.$$

- Gráficamente:
 - Si $n = 1$: rectas
 - Si $n = 2$: planos
 - Si $n > 2$: hiperplanos

2. Definición del problema

Espacio de hipótesis

- $\mathbf{w}$ es el *vector de pesos*.
- El término w_0 (ordenada en el origen) tiene un papel diferente a los demás pesos. Podemos suprimir esta diferencia introduciendo una variable ficticia x_0 cuyo valor es siempre $x_0 = 1$.
- De esta forma h es simplemente el producto escalar del vector de pesos y la entrada (o el producto matricial de su traspuesta y la entrada):


$$h_{\mathbf{w}}(\mathbf{x}_j) = \mathbf{w} \cdot \mathbf{x}_j = \mathbf{w}^\top \mathbf{x}_j = \sum_i w_i x_{j,i}.$$

2. Definición del problema

Espacio de hipótesis

- $\mathbf{w}$ es el vector de pesos.
- Cada vector de pesos *representa biunívocamente una hipótesis*.
- Por tanto, elegir una hipótesis y elegir un vector de pesos son la misma cosa.
- ¿Que vector de pesos debemos elegir?

En principio, el que **minimiza la función de pérdida** (empírica)



3. FUNCIÓN DE PÉRDIDA Y COSTE

3. Función de pérdida y coste

Error cuadrático

- Sea x una entrada, y la salida $y = f(x)$, e $\hat{y}$ el valor predicho $\hat{y} = h(x)$.
- La *pérdida* $L(y, \hat{y})$ es la cantidad de utilidad que se pierde por hacer esta predicción.
- Para la regresión, una función de pérdida muy conveniente es el *error cuadrático* L_2 :

Squared-error loss:
$$L_2(y, \hat{y}) = (y - \hat{y})^2$$

3. Función de pérdida y coste

Pérdida empírica/de generalización

- Nos gustaría considerar el conjunto $\mathcal{E}$ de *todos los puntos posibles* (x, y) , teniendo en cuenta sus probabilidades. Para una hipótesis h , promediando sobre este conjunto obtendríamos su *pérdida de generalización* :

$$\text{GenLoss}(h) = \sum_{(x,y) \in \mathcal{E}} L(y, h(x))p(x, y)$$

(quizás la suma debería ser una integral, pero el lector sabra disculparnos)

- ¿Qué puntos son los de $\mathcal{E}$? No lo sabemos; así que en su lugar consideramos el *conjunto de datos* E *disponible* y calculamos la *pérdida empírica*:

$$\text{EmpLoss}_E(h) = \frac{1}{|E|} \sum_{(x,y) \in E} L(y, h(x))$$

3. Función de pérdida y coste

Ejemplo

- Ejemplo: sean los datos de la tabla

$N=4, n=2$.

- Sea la hipótesis h :

$$h(x_1, x_2) = 0.5 + x_1 + x_2$$

j	x_1	x_2	y
1	1.0	0.1	1.7
2	0.0	0.7	1.3
3	2.1	1.7	4.1
4	1.5	2.1	4.0

- Será

j	x_1	x_2	y	$\delta = y_j - (0.5 + x_{1j} + x_{2j})$
1	1.0	0.1	1.7	0.1
2	0.0	0.7	1.3	0.1
3	2.1	1.7	4.1	-0.2
4	1.5	2.1	4.0	-0.1

- Y la pérdida (empírica) es

$$L = \frac{1}{4} \times (0.1^2 + 0.1^2 + (-0.2)^2 + (-0.1)^2) = 0.0175$$

3. Función de pérdida y coste

Función de pérdida

- Nótese que la hipótesis h está completamente determinada por el vector de pesos $(w_0, \dots, w_n)$.
- Así que, dado un conjunto de datos E , la pérdida es función de las $n + 1$ variables $w_0, \dots, w_n$, como se muestra gráficamente en la siguiente transparencia.
- Y la idea es encontrar los pesos $(w_0^*, \dots, w_n^*)$ tales que la pérdida sea mínima para el conjunto de datos E :

$$\mathbf{w}^* = \operatorname{argmin}_{\mathbf{w}} \operatorname{Loss}(h_{\mathbf{w}}).$$

3. Función de pérdida y coste

Visualización de $L_2(\mathbf{w})$ en un ejemplo




Figure 19.13 (a) Data points of price versus floor space of houses for sale in Berkeley, CA, in July 2009, along with the linear function hypothesis that minimizes squared-error loss: $y = 0.232x + 246$. (b) Plot of the loss function $\sum_j (y_j - w_1 x_j + w_0)^2$ for various values of w_0, w_1 . Note that the loss function is convex, with a single global minimum.

3. Función de pérdida

Función de coste

- Para seleccionar una hipótesis h , minimizar la pérdida puede que no sea el único objetivo. También podemos querer que h sea sencilla, es decir, que tenga una baja **complejidad**.
- Definimos el **coste** como la suma ponderada de la pérdida y la complejidad y minimizamos el coste:

$$Cost(h) = EmpLoss(h) + \lambda Complexity(h)$$

$$\hat{h}^* = \operatorname{argmin}_{h \in H} Cost(h).$$

λ es un número positivo.

3. Función de pérdida

Regularización

- El proceso de penalizar las hipótesis complejas se llama **regularización**: queremos que la hipótesis sea “regular”.
- Nótese que debemos definir dos funciones diferentes:
 - la función de pérdida;
 - y la medida de complejidad, que se denomina **función de regularización**.
- Para cada espacio de hipótesis tendrá sentido definir una función de regularización u otra.

3. Función de pérdida

Regularización para la regresión lineal

- Para las funciones lineales la complejidad es una *función de los pesos*.
- Se suelen usar funciones de la forma:

$$Complexity(h_{\mathbf{w}}) = L_q(\mathbf{w}) = \sum_i |w_i|^q.$$

donde q es un número natural.

3. Función de pérdida

Regularización para la regresión lineal

- Para $q = 1$ tenemos la regularización L_1 :

$$\text{Complexity} = L_1(\mathbf{w}) = |w_1| + |w_2| + \dots + |w_n|$$

y minimizamos

$$\text{Cost} = \text{EmpLoss} + \lambda (|w_1| + |w_2| + \dots + |w_n|)$$

- Para $q = 2$ tenemos la regularización L_2 :

$$\text{Complexity} = L_2(\mathbf{w}) = |w_1|^2 + |w_2|^2 + \dots + |w_n|^2$$

y minimizamos

$$\text{Cost} = \text{EmpLoss} + \lambda (|w_1|^2 + |w_2|^2 + \dots + |w_n|^2)$$

3. Función de pérdida

Regularización para la regresión lineal

- Si algún peso $w_i = 0$, la hipótesis se llama *dispersa*; se están descartando algunas variables de las dadas originalmente.
- Estas hipótesis dispersas suelen ser preferibles (p. ej., son más fáciles de interpretar).
- Al aplicar la regularización L_1 , frecuentemente la hipótesis de mínimo coste es dispersa. Por ello la regularización L_1 se usa mucho en regresión lineal.

3. Función de pérdida

Ejemplo (cont.)

□ Conjunto de datos: $N=4, n=2$

□ Hipótesis h :


$$h(x_1, x_2) = 0.5 + x_1 + x_2$$

- EmpLoss = 0.0175
- Complexity (L_1) = $0.5 + 1 + 1 = 2.5$
- Complexity (L_2) = $0.25 + 1 + 1 = 2.25$

□ Si $\lambda = 0.01$:

- Coste (regularización L_1) = 0.0425
- Coste (regularización L_2) = 0.0400

j	x_1	x_2	y
1	1.0	0.1	1.7
2	0.0	0.7	1.3
3	2.1	1.7	4.1
4	1.5	2.1	4.0



4. DESCENSO DEL GRADIENTE

4. Descenso del gradiente

Planteamiento

- $\mathbf{w}$ es el vector de pesos.
- Cada vector de pesos *representa biunívocamente una hipótesis*.
- Por tanto, elegir una hipótesis y elegir un vector de pesos son la misma cosa.
- ¿Que vector de pesos debemos elegir?
El que **minimiza la función de pérdida empírica; o la función de coste (si aplicamos regularización)**.

4. Descenso del gradiente

Planteamiento

- Hay que minimizar una función de varias variables.
- Una condición necesaria para que una función f alcance un mínimo en un punto $\mathbf{x}$ es que sus derivadas parciales en $\mathbf{x}$ respecto a $w_0, \dots, w_n$ sean 0. Es decir, para todo i ha de ser en $\mathbf{x}$



$$\frac{\partial L}{\partial w_i} = 0$$

- El vector formado por las derivadas parciales se llama *gradiente*. La dirección del vector gradiente es aquella en la que $f(\mathbf{x})$ crece más rápidamente.

4. Descenso del gradiente

Planteamiento

En dos dimensiones podemos visualizar el “campo de gradientes” de una función:



4. Descenso del gradiente

Planteamiento

□ Nota:

La condición

$$\frac{\partial L}{\partial w_i} = 0$$

es necesaria, pero en general no es suficiente para que L sea mínima (p. ej., podría ser mínima solo localmente, o podría ser máxima).

- Sin embargo, si la función es *convexa*, la condición es también suficiente.
- La función de pérdida empírica para un modelo lineal es convexa.

4. Descenso del gradiente

Planteamiento

- Para la función de pérdida empírica en la regresión lineal es posible resolver *analíticamente* el conjunto de ecuaciones y obtener una formula cerrada que da los pesos óptimos $\mathbf{w}^* = (w^*_0, \dots, w^*_n)$ como función de los valores del conjunto de datos (suponemos que el lector conoce la fórmula por sus estudios de Estadística; sin embargo, tal fórmula ahora no nos importa)
- Pero para otras funciones de pérdida o de coste no es así y debemos resolver *numéricamente* el problema.
- Usaremos el método del *descenso del gradiente*.

4. Descenso del gradiente


Definición informal

- El método se puede describir informalmente como sigue:
 1. Elegir un punto inicial x_0
 2. $x \leftarrow x_0$
 3. Calcular el gradiente de f en x
 4. Hasta que el gradiente sea 0 (o “muy pequeño”)
 5. Modificar “un poco” x en la dirección contraria a la del gradiente
 6. Calcular el gradiente de f en x
 7. Devolver $x, f(x)$

4. Descenso del gradiente

Definición informal

Gráficamente:



4. Descenso del gradiente

Definición formal

w $\leftarrow$ any point in the parameter space

while not converged do

for each w_i in w do

$$w_i \leftarrow w_i - \alpha \frac{\partial}{\partial w_i} Loss(\mathbf{w})$$

Gradient descent

El parámetro $\alpha > 0$ (el **paso**) se suele llamar **tasa de aprendizaje** cuando estamos minimizando la pérdida en un problema de aprendizaje. Puede ser constante, o disminuir en cada paso del algoritmo.

4. Descenso del gradiente

¿¿¿¿¿Derivadas parciales???

¡Tranquilo! Hay que calcular $\frac{\partial L}{\partial w_i}$ ($i = 0, \dots, n$)
 L es el error cuadrático. Sea

$$\delta_j = y_j - (w_0x_{j,0} + w_1x_{j,1} + \dots + w_nx_{j,n})$$

Entonces

$$\begin{aligned}\frac{\partial L}{\partial w_i} &= \frac{\partial}{\partial w_i} \frac{1}{N} \sum_j \delta_j^2 \\ &= \frac{1}{N} \sum_j \frac{\partial}{\partial w_i} \delta_j^2 \\ &= \frac{2}{N} \sum_j \delta_j \frac{\partial \delta_j}{\partial w_i} \\ &= -\frac{2}{N} \sum_j \delta_j x_{j,i} \\ &= -\frac{2}{N} \sum_j (y_j - (w_0x_{j,0} + w_1x_{j,1} + \dots + w_nx_{j,n}))x_{j,i}\end{aligned}$$

4. Descenso del gradiente

Definición

- Por tanto, los pesos se actualizan en paralelo según la siguiente regla:

$$w_i \leftarrow w_i + \alpha \frac{1}{N} \sum_{j=1}^{j=N} (y_j - (w_0 x_{j,0} + w_1 x_{j,1} + \dots + w_n x_{j,n})) x_{j,i}$$

con $\alpha > 0$, donde ahora llamamos α a lo que sería -2α (por eso el signo ha cambiado).

- Nota: recuérdese que $x_{j,0} = 1$ para todo j

4. Descenso del gradiente

Definición

- O sea, para actualizar cada peso w_i :
 1. Para cada dato multiplicar el error cometido en ese dato por el valor del rasgo correspondiente x_i .
 2. Promediar los valores obtenidos para todos los datos.
 3. Multiplicar por la tasa de aprendizaje $\alpha > 0$.
 4. Sumar el resultado al valor anterior del peso.
- Nótese que los pesos se actualizan en paralelo: para actualizarlos se tienen en cuenta sus valores en el paso anterior.

4. Descenso del gradiente

Definición

El algoritmo queda así ($\alpha > 0$):

w $\leftarrow$ any point in the parameter space

while not converged do

 for each w_i in **w** **do in parallel**

$$w_i \leftarrow w_i + \alpha \frac{1}{N} \sum_{j=1}^{j=N} (y_j - (w_0 x_{j,0} + w_1 x_{j,1} + \dots + w_n x_{j,n})) x_{j,i}$$

4. Descenso del gradiente

Ejemplo (cont.)

- Supongamos $\alpha = 0.1$

j	x_0	x_1	x_2	y	δ	$\delta \times x_0$	$\delta \times x_1$	$\delta \times x_2$
1	1.0	1.0	0.1	1.7	0.1	0.1	0.1	0.01
2	1.0	0.0	0.7	1.3	0.1	0.1	0.0	0.07
3	1.0	2.1	1.7	4.1	-0.2	-0.2	-0.42	-0.34
4	1.0	1.5	2.1	4.0	-0.1	-0.1	-0.15	-0.21
Σ						-0.1	-0.47	-0.47
Σ/N						-0.25	-0.1175	-0.1175

- Ahora:

$$\begin{aligned}w_0 &\leftarrow 0.5 + 0.1 \times -0.25 = 0.4975 \\w_1 &\leftarrow 1 + 0.1 \times -0.1175 = 0.98825 \\w_2 &\leftarrow 1 + 0.1 \times -0.1175 = 0.98825\end{aligned}$$

4. Descenso del gradiente

Ejemplo (cont.)

□ Ejemplo:

- Inicialmente la pérdida era $L = 175e-4$
- Después de un paso es $L=130e-4$
- Después de 500 pasos es

$$w_0 = 0.6809$$

$$w_1 = 0.9036$$

$$w_2 = 0.9173$$

$$L = 9.8e - 4$$

(Resolviendo analíticamente el problema, podemos comprobar que este es realmente el mínimo)

4. Descenso del gradiente

Descenso estocástico del gradiente

- El descenso del gradiente es una herramienta estándar de Cálculo Numérico. La versión arriba presentada se suele llamar *descenso del gradiente por lotes (Batch Gradient Descent)*.
- Otra variante es el descenso estocástico del gradiente (*Stochastic Gradient Descent*, SGD), que es una de las técnicas más populares en aprendizaje automático.
- En SGD no se usa el verdadero gradiente, sino una estimación.
- ¿Cuál? Una muy intuitiva: calculamos el gradiente de la pérdida **considerando solo un ejemplo**.
- Esto es menos costoso computacionalmente.
- Y, si se cumplen ciertas condiciones sobre E y α , se puede demostrar que SGD converge a un mínimo de la pérdida empírica.

4. Descenso del gradiente

Descenso estocástico del gradiente

- Para la regresión lineal, al usar SGD los pesos se actualizan en paralelo según la siguiente regla:

$$w_i \leftarrow w_i + \alpha(y_j - (w_0x_{j,0} + w_1x_{j,1} + \dots + w_nx_{j,n}))x_{j,i}$$

donde j es el índice de un ejemplo del conjunto de datos.

- Por ejemplo, si los ejemplos se van generando uno a uno, podemos ir actualizando los pesos conforme se van generando los ejemplos, “sobre la marcha”.
- Por ello el SGD se denomina también *on-line GD*.

4. Descenso del gradiente

Descenso estocástico del gradiente

- El algoritmo queda así ($\alpha > 0$):

w $\leftarrow$ any point in the parameter space

while not converged do

 select example j

 for each w_i in **w do in parallel**

$$w_i \leftarrow w_i + \alpha(y_j - (w_0x_{j,0} + w_1x_{j,1} + \dots + w_nx_{j,n}))x_{j,i}$$

4. Descenso del gradiente

Ejemplo (cont.)

- Supongamos que $\alpha = 0.1, j = 1$

j	x_0	x_1	x_2	y	δ	$\delta \times x_0$	$\delta \times x_1$	$\delta \times x_2$
1	1.0	1.0	0.1	1.7	0.1	0.1	0.1	0.01

- Entonces:

$$w_0 \leftarrow 0.5 + 0.1 \times 0.1 = 0.51$$

$$w_1 \leftarrow 1.0 + 0.1 \times 0.1 = 1.01$$

$$w_2 \leftarrow 1.0 + 0.1 \times 0.01 = 1.001$$

$$L = 212e-4 \text{ (¡¡mayor que el inicial!!)}$$

4. Descenso del gradiente

Ejemplo (cont.)

- Pero tras 2000 pasos (considerando en cada paso un ejemplo aleatorio del conjunto de datos) tenemos:

$$w_0 = 0.6801$$

$$w_1 = 0.8966$$

$$w_2 = 0.9180$$

$$L = 10e-4$$

- Nota: en cada paso t , $\alpha = 200/(2000 + t)$

4. Descenso del gradiente

Minibatches

- El **descenso del gradiente por minibatches** es una variante intermedia: en cada paso del algoritmo un *minibatch* de m ejemplos es seleccionado del conjunto total de N ejemplos.
- El gradiente se estima considerando en cada paso los errores cometidos en los ejemplos de **un** minibatch.
- El tamaño m del minibatch se ajusta para aprovechar al máximo las características de la arquitectura del ordenador.

4. Descenso del gradiente

Minibatches

El algoritmo queda así ($\alpha > 0$) :

$\mathbf{w} \leftarrow$ any point in the parameter space

Partition the dataset in K minibatches $MB_1, \dots, MB_K$

while not converged do

 for every minibatch MB_k **do**

 for each w_i in $\mathbf{w}$ **do in parallel**

$$w_i \leftarrow w_i + \alpha \frac{1}{m} \sum_{j \in MB_k} (y_j - (w_0 x_{j,0} + w_1 x_{j,1} + \dots + w_n x_{j,n})) x_{j,i}$$

4. Descenso del gradiente

Minibatches

- Una sucesión de pasos que comprende todos los ejemplos se denomina una *época*.
- Para alcanzar la condición de convergencia será necesario ejecutar varias épocas.



5. CONCLUSIÓN

5. Conclusión

- **¡Importante!** Recuerda que esto es solamente el ENTRENAMIENTO.
- El siguiente paso será VALIDAR/PROBAR la hipótesis obtenida.

5. Conclusión

- ❑ La **regresión lineal** es una técnica sencilla y en muchos casos útil para predecir salidas en función de las entradas (valores continuos)
- ❑ Para hallar la hipótesis de **menor error cuadrático** existen fórmulas cerradas (ver el curso de estadística).
- ❑ Aquí hemos presentado técnicas más versátiles: el **descenso del gradiente** y su variante el **descenso estocástico del gradiente**.
- ❑ La **regularización** busca hipótesis que se ajusten “bien” a los datos y a la vez sean “sencillas”.